

计算实验研究报告

三参数威布尔分布 MDM 方法 最优梯度偏移量 δ 的确定

*How to Choose the Optimal Gradient-Offset δ
in the Minimum Discrepancy Method for the 3-Parameter Weibull Distribution*

一句话结论

梯度偏移量 δ 不是可有可无的微调参数，而是 MDM 方法能否稳定求解三参数威布尔分布的**关键开关**。

经典的 $\nabla=0$ ($\delta=0$) 准则因落在 $\sigma_{\min}$ 曲线的**平坦谷底**而严重失稳；引入正向偏移 $\delta>0$ 把解推到陡峭的右翼，可显著降低估计误差。

是否存在唯一**全局最优 δ** ？**不存在**。最优 δ 系统性地依赖形状参数 β （主导因素）与样本量 n ，需要**分层或自适应**选取。

基于 150 组参数场景 × 每组 300 次蒙特卡罗重复的实测结果
全部图表与数据均由实际仿真生成，可完全复现

目录

摘要

本文针对三参数威布尔分布的**最小差异法**（Minimum Discrepancy Method，简称 MDM）中的**梯度偏移量 δ** 展开系统的计算实验研究。MDM 通过在剖面标准差曲线 $\sigma_{\min}(\gamma)$ 上寻找梯度等于给定偏移量的位置来估计位置参数 γ ，再回代得到形状参数 β 与尺度参数 η 。偏移量 δ 的取值直接决定估计的稳定性与精度，但其**最优取值如何确定**一直缺乏系统结论。本研究的目标，是给出**一套可操作的、用于获得并应用最优 δ 的方法**。

我们首先通过对 $\sigma_{\min}(\gamma)$ 几何形态的诊断，澄清了一个被以往讨论忽视的事实：该曲线是一个**宽底的“碗”形**，右侧随 $\gamma \rightarrow t_{\min}$ 急剧抬升形成“陡壁”，真实 γ 恰落在这道**上升的右翼上**。这解释了为何经典 $\nabla=0$ （碗底）准则会剧烈漂移、位置估计经常“贴边”到 $t_{\min}$ 。引入正向偏移 $\delta > 0$ ，相当于把解点从不稳定的碗底沿陡翼**向右推到斜率 $= \delta$ 的位置**，从而获得唯一且稳定的解。

基于 **$6 \times 5 \times 5 = 150$ 组参数场景**（样本量 $n \in \{5, \dots, 100\}$ ，形状 $\beta \in \{0.8, \dots, 5\}$ ，相对位置 $\gamma/\eta \in \{0, \dots, 0.5\}$ ），每组 **300 次重复**、共 **12 个候选 δ** 的完整蒙特卡罗实验，我们得到以下主要结论：

- **最优 δ 确实存在，但不唯一。** 以归一化误差 NE 度量， δ -误差曲线在每个场景下都有清晰的极小点；但极小点位置因场景而异。
- **形状参数 β 是主导因素。** 随 β 由 0.8 增大到 5，最优 δ 从约 **1.0** 单调下降到约 **0.05**（量纲为原始数据单位）。
- **样本量 n 是次要因素。** 给定 β 时， n 越大、最优 δ 越小。
- **常用默认值 $\delta=0.1$ 并非全局最优。** 它在 $\beta \approx 3$ 附近恰好接近最优，但对小 β （重尾）明显偏小、对大 β 略偏大。
- **分层/自适应可带来稳定收益。** 按 β 分层相对固定 $\delta=0.1$ 平均降低 NE 约 **12%**，全场景分层约 **13%**，逐样本理论上界约 **31%**。

据此，本文给出**面向实践的最优 δ 选取流程**（详见第八、九节）：在缺乏先验时，可由样本先估计 β ，再据 β （和 n ）查表/套用经验式确定 δ ，最后以该 δ 重新运行 MDM 得到最终参数估计。

一、研究背景与问题定义

1.1 三参数威布尔分布

三参数威布尔分布在可靠性工程、寿命数据分析、材料强度建模等领域应用广泛。其累积分布函数（CDF）为：

$$F(t) = 1 - \exp\{ -[(t - \gamma) / \eta]^\beta \}, \quad t \geq \gamma$$

其中三个参数分别为：

- **形状参数** $\beta > 0$ ：控制失效率曲线形态。 $\beta < 1$ 对应递减失效率（早期失效）， $\beta = 1$ 退化为指数分布， $\beta > 1$ 对应递增失效率（耗损失效）。
- **尺度参数** $\eta > 0$ ：特征寿命，决定分布的横向伸缩。
- **位置参数** γ （又称阈值/起始参数）：分布的左端起点， $t < \gamma$ 时概率为 0。 γ 的估计是三参数情形的**难点**所在。

1.2 MDM 方法与梯度偏移量 δ

最小差异法（MDM）是一类基于**剖面化**思想的图估计/矩混合方法。其核心观察是：若把 γ 视为已知并固定，则三参数问题退化为两参数威布尔的线性化拟合，可以解析地求出对应的 β 与 η ，并得到一个“拟合优度”或“离散度”指标。MDM 把这个指标记为剖面标准差 $\sigma_{\min}(\gamma)$ ，并以它对 γ 的变化关系来反推真实的 γ_0 。

理想情况下，人们希望在 $\sigma_{\min}(\gamma)$ 的**极小点**（即梯度 $\nabla(\gamma) = d\sigma_{\min}/d\gamma = 0$ 处）取得 γ 的估计。然而在有限样本下，这个极小点往往**不稳定**。为此，MDM 引入一个**梯度偏移量** δ ，改用如下条件确定 γ ：

$$\text{求 } \hat{\gamma} \text{ 使得 } \nabla(\hat{\gamma}) = d\sigma_{\min} / d\gamma = \delta \quad (\delta \geq 0)$$

当 $\delta=0$ 时退化为经典的 $\nabla=0$ 准则。 $\delta>0$ 时，解点被移动到曲线斜率恰好等于 δ 的位置。本文采用**原始量纲**的 δ （即不对 η 归一化），与工程实践中直接在数据尺度上设定阈值的习惯一致。

1.3 核心问题

围绕**如何确定最优的梯度偏移量** δ ，本文要回答的核心问题包括：

1. **是否存在最优 δ ?** 它是全局唯一的，还是依赖样本量、依赖参数组合，甚至逐样本不同？
2. 如果存在多个层次的“最优”（全局/按 n /按参数组合/逐样本），能否在每个层次上给出一个最优 δ ，并由用户按收益自行选择层次？
3. 各层次的最优 δ 相对常用默认值 $\delta=0.1$ 能带来多大精度提升？
4. 若不存在唯一最优 δ ，究竟是哪些因素在驱动它的变化？
5. 给定一个具体参数组合，**如何计算**它的最优 δ ，又**如何把该 δ** 应用回去以提升 MDM 的估计精度？
6. 最终给出怎样的推荐：保持 0.1 / 改用新的固定值 / 按 n 分段 / 按 β （或 γ/η ）分段 / 采用自适应 δ ？

二、MDM 估计量的数学描述

2.1 经验分布与线性化

设有序样本 $t_{(1)} \leq t_{(2)} \leq \dots \leq t_{(n)}$ 。对第 i 个次序统计量赋经验累积概率（中位秩 / Bernard 近似）：

$$F_i = (i - 0.3) / (n + 0.4), \quad i = 1, 2, \dots, n$$

威布尔 CDF 经两次取对数可线性化。定义**线性化横坐标**（仅依赖于 n ）：

$$x_i = \ln[-\ln(1 - F_i)]$$

若位置参数 γ 已知，则 $\ln(t_{(i)} - \gamma)$ 与 x_i 之间应近似为线性关系，斜率为 $1/\beta$ 、截距为 $\ln \eta$ 。

2.2 给定 γ 的剖面估计

对任意试探值 $\gamma < t_{(1)}$ ，构造每个次序点对应的“伪尺度”：

$$\hat{\eta}_i(\gamma, \beta) = (t_{(i)} - \gamma) / x_i^{1/\beta}$$

其中 $x_i^{1/\beta}$ 取自标准威布尔分位。理想模型下这些 $\hat{\eta}_i$ 应彼此相等（都等于 η ）。MDM 用它们的**样本标准差**衡量离散程度：

$$S(\gamma, \beta) = \text{sd}_i \{ \hat{\eta}_i(\gamma, \beta) \}$$

对每个固定的 γ ，在 β 方向最小化离散度，得到**剖面标准差曲线**：

$$\sigma_{\min}(\gamma) = \min_{\beta > 0} S(\gamma, \beta), \quad \beta^*(\gamma) = \operatorname{argmin}_{\beta} S(\gamma, \beta)$$

相应地，给定 γ 的尺度估计取伪尺度均值 $\hat{\eta}(\gamma) = \text{mean}_i \hat{\eta}_i(\gamma, \beta^*)$ 。

2.3 偏移量条件与最终估计

MDM 的位置参数估计由梯度偏移量条件给出：

$$\nabla(\gamma) \equiv d\sigma_{\min} / d\gamma, \quad \text{取 } \hat{\gamma} \text{ 使 } \nabla(\hat{\gamma}) = \delta$$

求得 $\hat{\gamma}$ 后回代，即得三参数的 MDM 估计：

$$\hat{\beta} = \beta^*(\hat{\gamma}), \quad \hat{\eta} = \hat{\eta}(\hat{\gamma}), \quad \hat{\gamma} = \text{（由上式确定）}$$

关于 δ 的量纲（重要）

由于 $\sigma_{\min}$ 与 η 同量纲、 γ 与数据 t 同量纲，斜率 $d\sigma_{\min}/d\gamma$ 是**无量纲**的。因此在数据整体缩放 $t \rightarrow c \cdot t$ 下，最优 δ 理论上**不随** η 改变。

这一尺度不变性在第七节用 $\eta=50/100/200$ 的实验得到验证，也意味着主实验固定 $\eta=100$ 不失一般性。

三、关键发现： $\sigma_{\min}(\gamma)$ 的几何形态

要理解 δ 为何重要、最优 δ 为何随场景变化，必须先看清剖面标准差曲线 $\sigma_{\min}(\gamma)$ 的真实形状。本节给出的诊断，是后续全部结论的几何基础。

3.1 “碗形 + 陡壁” 结构

如图 1 所示， $\sigma_{\min}(\gamma)$ 在 γ 从很小（远离数据）增大到 $t_{(1)}$ 的过程中，呈现三段式形态：

- **左侧高位：**当 γ 远小于数据时，伪尺度被严重拉伸，离散度高；
- **宽阔的平坦谷底：**中段存在一大片近乎水平的极小区域，斜率接近 0；
- **右侧陡壁：**当 $\gamma \rightarrow t_{(1)}$ 时，曲线急剧上升，斜率迅速增大乃至发散。

Geometry of the MDM criterion: the $\sigma_{\min}$ bowl and the gradient-offset stops (colored = $\delta = 0, .05, .10, .20, .50$)




图1 $\sigma_{\min}(\gamma)$ 的“碗形 + 陡壁”结构及不同 δ 的解点（上：曲线本身；下：其斜率）。绿色虚线为真实 γ ，红色点线为 $t_{\min}$ 。可见真实 γ 落在右侧上升翼上； δ 越大，解点沿陡壁越靠近 $t_{\min}$ 。

3.2 为什么经典 $\nabla=0$ 准则会失稳

真实的 γ 并不在碗底，而是在**碗底与 $t_{(1)}$ 之间的上升右翼上**——在该处斜率为**正**。这带来两个直接后果：

1. **$\nabla=0$ （碗底）严重偏左、且位置漂移剧烈。** 由于谷底平坦，其最低点位置对样本噪声极其敏感，在不同样本间可从很负的值一直跳到接近 $t_{(1)}$ ，导致 $\hat{\gamma}$ 方差巨大。
2. **位置估计容易“贴边”。** 一旦谷底最低点落到陡壁附近， $\hat{\gamma}$ 就会紧贴 $t_{(1)}$ ，使 $(t_{(1)} - \hat{\gamma})$ 趋近 0， $\hat{\beta}$ 、 $\hat{\eta}$ 随之崩坏。

实验佐证：在示例场景下， $\delta=0$ 的异常率高达 6.3%、位置“贴边”比例 **31.9%**，而 γ 的 RMSE 达 **54.5**（均为原始量纲）。这正是文献中“ $\nabla=0$ 解 γ 波动很大、可能贴近 $t_{\min}$ ”现象的几何根源。

3.3 正向偏移 δ 的稳定化作用

把判据从“找碗底”改成“找斜率 $= \delta$ 的点”，并沿陡翼**向右**搜索，带来本质改善：陡壁处斜率随 γ 快速且单调上升，使方程 $\nabla(\gamma)=\delta$ 存在**唯一且稳定**的根——斜率曲线越陡，根对噪声越不敏感。

- 当 $\delta \rightarrow 0^+$ 时，解点回到碗底附近；
- 当 δ 增大时，解点沿陡壁**向右上方移动**，逐步靠近 $t_{\min}$ ；
- 因此存在一个**恰到好处**的 δ ，使 $\hat{\gamma}$ 命中真实 γ ——这就是“最优偏移量”的几何含义。

严格交点不存在 $\neq$ MDM 无解

对个别样本（尤其 $\beta < 1$ 、碗底贴边的情形），陡翼可能不完整，方程 $\nabla(\gamma)=\delta$ 在区间内**没有严格内点根**。此时 MDM 退化为**约束解**：取可行域内最接近 $t_{\min}$ 的点作为 $\hat{\gamma}$ （并标记 `strict_root=False`），仍给出有效估计。

实验中“严格根存在率”随 δ 增大而升高（从 $\delta=0.01$ 的约 **73%** 升至 $\delta=0.3$ 的约 **90%**），说明适度增大 δ 也有助于“求得到解”。详见第七节。

四、实验设计与评价指标

4.1 参数场景网格

为在可控算力下覆盖代表性情形，设计如下因子网格（共 **150 组场景**，尺度统一固定 $\eta = 100$ ）：

因子	取值	水平数	说明
样本量 n	5, 10, 20, 30, 50, 100	6	覆盖极小样本到中等样本
形状 β	0.8, 1.2, 2, 3, 5	5	含 $\beta < 1$ 重尾与 $\beta > 1$ 耗损型
相对位置 γ/η	0, 0.05, 0.1, 0.2, 0.5	5	$\gamma = (\gamma/\eta) \cdot \eta$ ，含 $\gamma = 0$ 边界
尺度 η	100（主网格）	1	另在子集测 50/200 验证不变性
偏移量 δ	0, 0.01, 0.03, 0.05, 0.08, 0.1, 0.15, 0.2, 0.3, 0.5, 0.7, 1	12	原始量纲； $\delta = 0$ 为经典对照， $\delta = 0.1$ 为基线

每组场景独立重复 **300 次**（不同随机种子），合计约 **45.0 万** 次三参数估计。所有 δ 共享同一条 $\sigma_{\min}(\gamma)$ 曲线（仅取根位置不同），因此计算高度复用、可在数分钟内完成。

4.2 归一化误差与评价指标

由于三个参数量纲不同（ γ 、 η 为数据单位， β 无量纲），需用统一的**归一化误差**（Normalized Error, NE）综合度量单次估计精度：

$$NE = \sqrt{((\hat{\beta} - \beta)/\beta)^2 + ((\hat{\eta} - \eta)/\eta)^2 + ((\hat{\gamma} - \gamma)/\eta)^2}$$

注意 γ 的误差用 η 归一化（而非用 γ ，因为 γ 可为 0）。NE 越小表示三参数整体越准。除 NE 外，还报告各参数的**偏差**（bias）、**RMSE**，以及下列稳健性/诊断指标：

- **异常率（anomaly rate）**：出现 NaN、或 $\hat{\beta}$ 触及网格边界、或 $\hat{\eta}$ 失控、或 $\hat{\gamma} \geq t_{\min}$ 、或 $NE > 5$ 的比例。
- **“贴边”率（hug rate）**： $(t_{\min} - \hat{\gamma})/\text{span} < 0.02$ 的比例，反映位置估计是否塌到样本最小值附近。
- **严格根存在率（strict-root rate）**：方程 $\nabla = \delta$ 在区间内有内点根的比例。

为抗极端值干扰，跨重复聚合时对 NE 设**封顶**（**cap=3**）后再取均值，并同时报告中位数；最优 δ 即按“封顶 NE 均值最小”选取。

4.3 五个“最优”层次

为回答“最优 δ 存在于哪个层次”，我们在五个粒度上分别求最优并比较：

层次	含义	所需先验
① 逐样本最优	每条样本各自挑使其 NE 最小的 δ	真参数（仅理论上界）
② 按 $(n, \beta, \gamma/\eta)$ 全场景	每个参数组合一个 δ	全部三参数 + n

层次	含义	所需先验
③ 按 β (或 $\beta, \gamma/\eta$)	按形状分层一个 δ	形状 β
④ 按 n	按样本量分层一个 δ	仅样本量 n
⑤ 全局固定	所有情形共用一个 δ	无

此外构造一个可落地的自适应规则 $\hat{\delta}(n, \hat{\beta})$: 先用样本估出 $\hat{\beta}$, 再据 $(n, \hat{\beta})$ 分箱查表取 δ 。它只依赖可观测量, 最接近真实使用场景。

五、单场景剖析： δ 如何改变估计

先用一个代表性场景（中等样本、含正位置参数）展示 δ 从 0 增大时各项误差的演化，建立直观认识，再进入全局统计。

表 1 给出该场景下随 δ 变化的关键指标。可清楚看到**先降后升**的单谷结构：

δ	NE	γ 偏差	γ RMSE	β 偏差	η RMSE	异常%	贴边%
0.00	0.855	-22.9	54.5	0.99	56.4	6.3	31.9
0.01	0.675	-19.2	46.0	0.82	48.3	0.0	30.2
0.03	0.450	-6.8	28.3	0.31	30.4	0.0	25.2
0.05	0.372	-1.3	22.8	0.07	24.9	0.0	22.1
0.08	0.327	3.7	19.8	-0.15	21.8	0.0	18.9
0.10	0.315	5.9	19.0	-0.24	21.0	0.0	17.6
0.15	0.311	10.0	18.7	-0.42	20.7	0.0	14.3
0.20	0.326	12.9	19.4	-0.55	21.3	0.0	12.2
0.30	0.372	16.8	21.1	-0.71	23.1	0.0	9.4
0.50	0.455	21.6	24.3	-0.88	26.6	0.0	5.6
0.70	0.504	24.5	26.6	-0.94	29.6	0.0	3.5
1.00	0.538	26.6	28.4	-0.97	32.5	0.0	0.2

表1 单场景下各指标随 δ 的演化（高亮行为该场景最优 $\delta = 0.15$ ）。量纲为原始数据单位。

解读：（1） $\delta=0$ 时异常率与贴边率最高、 γ RMSE 最大，印证 $\nabla=0$ 的不稳定；（2）随 δ 增大， γ 偏差由负（偏小、偏左）穿过 0 转为正（偏大、偏右），存在一个使偏差 ≈ 0 的**甜点**；（3）NE 在该甜点附近取最小（本例 $\delta\approx 0.15$ ，NE=0.311），随后因解点过度右移、 $\hat{\gamma}$ 贴近 $t_{\min}$ 而回升。

从单场景得到的两点认识

- 偏移量 δ 的作用是把解点沿陡翼平移，本质是在“位置偏小（ δ 太小）”与“位置偏大／贴边（ δ 太大）”之间做权衡。
- 因此一定存在**某个最优 δ** 使权衡最佳；问题只在于这个最优值**随场景如何移动**——这正是下一节的主题。

六、最优 δ 是否存在？由什么驱动？

6.1 最优 δ 确实存在（但不唯一）

把每个形状 β 下的 NE 对 δ 作曲线（图 2），可见每条曲线都有清晰的极小点（星号），即最优 δ 存在。但不同 β 的极小点位置明显不同，说明不存在跨场景唯一的全局最优。




图2 不同形状 β 下归一化误差随 δ 的变化（★为各自最优）。所有曲线在 δ 过小处急升（ $\nabla \approx 0$ 失稳），但最优位置随 β 显著左移： β 越大、最优 δ 越小。虚线为常用 $\delta=0.1$ 。

两个普遍特征值得注意：（1）**左侧惩罚陡峭**—— δ 取得过小时所有曲线急剧恶化，说明“宁可稍大、不可过小”；（2）**右侧惩罚因 β 而异**——大 β 在 δ 偏大时迅速变差，小 β 则较为平缓。

6.2 主导因素：形状参数 β

按 β 求最优 δ ，得到强烈的单调关系（表 2、图 3 左）：

形状 β	最优 δ^*	NE($\delta=0$)	NE(δ^*)	相对 $\delta=0$ 降幅
0.8	1.00	0.498	0.362	-27%
1.2	0.70	0.548	0.307	-44%
2	0.20	0.754	0.335	-56%
3	0.10	1.029	0.409	-60%
5	0.05	1.281	0.523	-59%

表2 按形状 β 的最优 δ 及其相对经典 $\nabla=0$ 的精度提升。

可见最优 δ 从 $\beta=0.8$ 的约 **1.00** 一路降到 $\beta=5$ 的约 **0.05**。直观解释：大 β 的右翼非常陡，很小的 δ 已足以把解点稳定在真值附近；小 β （重尾）的翼较缓且谷底更宽，需要更大的 δ 才能把解点推到位。

6.3 次要因素：样本量 n 与相对位置 γ/η

固定其余因子，最优 δ 随 n 增大而**减小**（表 3）：样本越多、 $\sigma_{\min}$ 曲线越光滑、谷底定位越可靠，所需人工偏移越小。

样本量 n	最优 δ^* (已知 n)	该 δ 下平均 NE
5	0.15	0.807
10	0.15	0.584
20	0.10	0.410
30	0.08	0.339
50	0.08	0.259
100	0.05	0.202

表3 按样本量 n 的最优 δ （在各 β 、 γ/η 上平均）。

相对位置 γ/η 的影响相对较弱：中位最优 δ 随 γ/η 增大略有下降，但幅度远小于 β 的作用，且与 β 存在交互。综合来看， **β 是第一主导、 n 次之、 γ/η 再次。**

How the optimal offset depends on the (unknown) parameters




图3 最优 δ 随各因子的变化趋势：随 β 增大单调下降（左，主导），随 n 增大下降（中），随 γ/η 变化较平缓（右）。

6.4 最优 δ 的二维图景

把最优 δ 在 (n, β) 平面上画成热图（图 4），最优 δ 的分布一目了然：沿 β 方向变化剧烈、沿 n 方向变化平缓。这再次确认 β 是选取 δ 时最值得关注的量。




图4 最优 δ 在 (n, β) 平面上的热图。颜色越深表示最优 δ 越大；可见随 β 增大（向右/下）迅速变浅，随 n 变化温和。

对问题①与④的直接回答

① 最优 δ 存在但不唯一：每个场景都有极小点，但极小点位置随场景移动，不存在对所有情形都最好的单一 δ 。

④ 驱动因素已查明：按重要性排序为 形状 β （强、单调递减）> 样本量 n （中、递减）> 相对位置 γ/η （弱）。

七、稳健性、约束解与尺度不变性

7.1 偏移量显著抑制异常与“贴边”

图 5 对比 $\delta=0$ 与 $\delta>0$ 的异常率与位置“贴边”率。经典 $\nabla=0$ 在小样本下异常率可观 ($n=5$ 时约 **12.2%**)，引入 $\delta=0.1$ 后几乎降为 **0** (总体 **0.0%**)。这说明偏移量首先是稳定器，其次才是精度调节器。




图5 偏移量对稳健性的作用：左为不同 n 下 $\delta=0$ 的异常率（小样本尤其高），右为引入 δ 后异常率/贴边率的下降。

7.2 约束解：严格根不存在不等于无解

表 4 给出严格内点根存在率随 δ 的变化。 δ 越大、陡壁被命中的概率越高，存在率单调上升；即便在 δ 很小时偶有“无严格根”，MDM 仍以约束解（取最接近 $t_{\min}$ 的可行点）给出有效估计，不会“求不出来”。

δ	0.01	0.05	0.1	0.2	0.3	0.5	1
严格根率	73%	83%	86%	89%	90%	91%	91%

表4 严格内点根存在率随 δ 的变化 ($\delta=0$ 必有碗底解，故为100%)。

此外，右翼存在性本身与 β 有关：图与数据显示 $\beta \geq 1.2$ 时几乎总有完整右翼（存在率 **> 99%**），而 $\beta=0.8$ 时约 **63%** 的样本右翼不全，需要更多依赖约束解——这也解释了为何小 β 需要更大的 δ 。




图6 严格根存在率随 δ 的上升, 以及不同 β 下右翼完整的样本比例。

7.3 尺度不变性：最优 δ 不依赖 η

第 2.3 节已论证斜率 $d\sigma_{\min}/d\gamma$ 无量纲, 故最优 δ 应与 η 无关。图 7 用 $\eta=50/100/200$ 的实验验证：三条 NE- δ 曲线几乎重合, 最优 δ 位置一致。




图7 尺度不变性验证: $\eta=50/100/200$ 下NE- δ 曲线高度重合, 最优 δ 不随尺度漂移。这表明在原始量纲下, 最优 δ 主要由形状 β 决定, 可直接迁移到不同 η 的数据。

一个实用推论

既然最优 δ 不随 η 改变, 使用者无需为不同尺度的数据重新标定 δ ; 只要按形状 β (及样本量 n) 选取即可。这大大简化了 δ 的工程应用。

八、不同选取策略的收益对比

本节定量回答：在各“最优”层次上能带来多大提升（问题②③），以固定 $\delta=0.1$ 为 0% 基线，正值表示 NE 相对下降（越大越好）。

选取层次（知道得越多，越靠下）	平均 NE	相对 $\delta=0.1$ 提升
固定 $\delta=0$ (经典 $\nabla=0$)	0.822	-87.0%
固定 $\delta=0.1$ (基线/常用)	0.440	+0.0%
全局最优固定 $\delta=0.1$	0.440	+0.0%
按 n 分层 (已知 n)	0.434	+1.4%
按 β 分层 (已知真 β)	0.387	+11.9%
按 $(\beta, \gamma/\eta)$ 分层	0.387	+12.0%
按 $(n, \beta, \gamma/\eta)$ 全场景分层	0.382	+13.0%
逐样本最优 (绝对上界)	0.303	+31.2%

表5 各层次最优 δ 相对固定 $\delta=0.1$ 的精度提升阶梯。




图8 知识层次阶梯：纵轴为相对固定 $\delta=0.1$ 的 NE 改善百分比。经典 $\delta=0$ 大幅劣化；按 β 分层即可获得大部分收益；逐样本最优给出理论上界。

8.1 关键读数

- 经典 $\delta=0$ 反而最差：相对 0.1 劣化约 **-87%**，再次说明“零偏移”不可取。
- 按 n 分层收益有限：仅约 **1.4%**。单凭样本量调 δ 帮助不大。
- 按 β 分层是性价比拐点：跃升至约 **12%**，已捕获全场景分层（**13%**）的绝大部分收益。说明形状 β 是值得花力气估计的关键先验。
- 逐样本最优是上界：约 **31%**，但需要真参数，现实不可达，仅作为衡量改进空间的标尺。

8.2 可落地的自适应规则 $\hat{\delta}(n, \hat{\beta})$

逐样本最优不可达，但可用只依赖可观测量的自适应规则逼近：先估 $\hat{\beta}$ ，再按 $(n, \hat{\beta})$ 查表取 δ 。下表给出在各 n 上、自适应与几种基准的对比（NE，越小越好）：

n	固定 $\delta=0.1$	按 n 最优	自适应 $\hat{\delta}(n, \hat{\beta})$	逐样本上界
5	0.836	0.818	0.812	0.714
10	0.598	0.590	0.589	0.506
20	0.411	0.411	0.408	0.362
30	0.342	0.341	0.338	0.306
50	0.266	0.261	0.255	0.235
100	0.208	0.203	0.197	0.186

表6 自适应规则与基准在各样本量上的NE 对比。

总体上，自适应规则相对固定 0.1 平均改善约 **2.4%**，介于“按 n 分层”与“按 β 分层”之间——因为 $\hat{\beta}$ 自身存在估计误差，吃掉了部分理想分层的收益。但它**无需任何真先验、完全数据驱动**，是现实中最值得采用的方案之一。若能从工程知识获得较准的 β 先验，则可直接用“按 β 分层”取得更大收益。

Bias/RMSE trade-off vs δ ($\beta=2, \gamma/\eta=0.1, n=30$): small δ under-shoots γ , large δ over-shoots toward t_{min}




图9 精度—稳健性权衡总览：不同策略在平均NE 与异常率上的位置，自适应/按 β 分层位于更优的左下方。

九、实操指南：如何获取并应用你的最优 δ

本节给出**面向使用者的完整流程**（直接回答问题⑤）：给定一批待分析数据，如何确定其最优 δ ，并用它得到更准的三参数威布尔估计。

9.1 推荐流程（三步法）

- 第一步：先做一次基线估计，得到 $\hat{\beta}$ 。**用稳健的默认 $\delta=0.1$ 跑一遍 MDM，得到初步的形状估计 $\hat{\beta}$ （此步只为给 δ 的选取提供依据，对应自适应规则中的“观测量”）。
- 第二步：据 $(n, \hat{\beta})$ 查表确定 δ 。**用本节表 7 的查找表（或 9.2 的经验式）得到推荐 δ 。样本量 n 已知， $\hat{\beta}$ 来自第一步。
- 第三步：用选定的 δ 重跑 MDM，输出最终估计。**以第二步的 δ 重新求解 $\nabla(\gamma)=\delta$ ，得到最终的 $(\hat{\beta}, \hat{\eta}, \hat{\gamma})$ 。若 $\hat{\beta}$ 在两步间变化很大，可迭代一次。

9.2 形状驱动的查找表与经验式

最简单实用的做法是**只按形状 β 选 δ** （性价比最高，见第八节）。推荐查找表如下：

估计到的 $\hat{\beta}$ 范围	推荐 δ （原始量纲）	适用说明
$\hat{\beta} < 1$ （重尾/早期失效）	0.7 - 1.0	右翼平缓、谷底宽，需较大偏移
$1 \leq \hat{\beta} < 1.5$	0.3 - 0.7	过渡区
$1.5 \leq \hat{\beta} < 2.5$	0.15 - 0.3	常见区间
$2.5 \leq \hat{\beta} < 4$ （含默认 0.1 适用区）	0.08 - 0.15	$\delta=0.1$ 在此接近最优
$\hat{\beta} \geq 4$ （强耗损）	0.05 左右	右翼很陡，小偏移即可

表 7 按估计形状 $\hat{\beta}$ 选取 δ 的推荐查找表。样本量越大，可取区间偏小端。

若需要连续取值，可用如下**经验近似式**（由表 2 拟合， δ 随 β 近似几何衰减）：

$$\delta^*(\beta) \approx 1.0 \times \beta^{-1.8} \quad (\beta \geq 0.8; \text{样本较大时再乘 } 0.6\text{--}0.8 \text{ 的折减})$$

例如 $\beta \approx 2$ 给出 $\delta \approx 0.3$ 、 $\beta \approx 3$ 给出 $\delta \approx 0.13$ 、 $\beta \approx 5$ 给出 $\delta \approx 0.05$ ，与实测最优一致。

9.3 应用效果：位置估计的改善

图 10 用箱线图对比 $\delta=0, 0.1$ 与最优 δ 下 $\hat{\gamma}$ 的分布。采用最优 δ 后， $\hat{\gamma}$ 的**中位数更贴近真值、四分位距更窄、“贴边”离群点显著减少**——这正是“提升 MDM 精度”在位置参数上的直接体现。




图10 $\delta=0 / 0.1 /$ 最优 δ 下位置估计 $\hat{\gamma}$ 的分布对比。最优 δ 使 $\hat{\gamma}$ 更集中于真值、贴边离群点更少。

9.4 何时可省略调参

- 若你的数据形状 β 已知在 2.5-4 之间，**直接用 $\delta=0.1$ 即可**，无需额外调参。
- 若 β 明显偏离该区间（尤其 $\beta < 1.5$ 或 $\beta > 4$ ），**务必按表 7 调整 δ** ，否则精度损失明显。
- 数据尺度 η 无论多大都**不影响 δ 选取**（尺度不变性）。

十、对核心问题的逐条回答

问题 1 是否存在最优 δ ? 全局唯一还是依赖场景?

答：存在最优 δ ，但**不是全局唯一**。每个场景的 NE- δ 曲线都有清晰极小点；最优位置主要随形状 β 变化 ($\beta \uparrow$ 则 $\delta^* \downarrow$)，并随样本量 n 增大而减小。逐样本的最优 δ 也各不相同。

问题 2 能否在多个层次各给一个最优 δ ，由用户按收益选层?

答：可以。本文给出五个层次（逐样本→全场景→按 β →按 n →全局）各自的最优 δ （表 2、3、5）。用户可据**自己掌握的先验**选层：知道形状就用按 β 分层，只知样本量就用按 n ，什么都不知就用全局 0.1 或数据驱动的自适应规则。

问题 3 各层次相对固定 $\delta=0.1$ 能提升多少?

答：以封顶 NE 均值计：按 n 分层约 +1%、按 β 分层约 +12%、全场景分层约 +13%、自适应 $\hat{\delta}(n, \hat{\beta})$ 约 +2%、逐样本理论上界约 +31%。逐场景看，最优相对 0.1 的中位改善约 12%。

问题 4 若无唯一最优，哪些因素在驱动它?

答：按重要性：① 形状 β （最强，单调递减且跨度大，从 ~ 1.0 到 ~ 0.05 ）；② 样本量 n （中等，递减）；③ 相对位置 γ/η （较弱）。而尺度 η 不影响（已由理论与实验共同确认）。

问题 5 给定参数组合，如何计算并应用其最优 δ ?

答：三步法（第九节）：① 用 $\delta=0.1$ 跑一次得 $\hat{\beta}$ ；② 据 $(n, \hat{\beta})$ 查表 7 或用经验式 $\delta^* \approx 1.0 \cdot \beta^{-1.8}$ 定 δ ；③ 用该 δ 重跑 MDM 得最终估计。若做仿真标定，则在你的 $(n, \beta, \gamma/\eta)$ 上扫 δ 取使 NE 最小者。

问题 6 最终推荐哪种方案?

答：分场景推荐（详见第十一节）：默认保留 0.1 仅适用于 $\beta \approx 3$ 的情形；更稳妥的做法是按形状 β 分层选 δ （性价比最高），或在无先验时采用数据驱动的自适应 $\hat{\delta}(n, \hat{\beta})$ 。不建议使用 $\delta=0$ （经典 $\nabla=0$ ）。

十一、结论与最终建议

11.1 主要结论

10. $\sigma_{\min}(\gamma)$ 是“碗形+陡壁”结构，真实 γ 在上升右翼上；经典 $\nabla=0$ 因谷底平坦而失稳，这是 MDM 需要偏移量 δ 的根本原因。
11. 正向偏移 $\delta>0$ 把解点沿陡翼推到斜率= δ 处，既**稳定**（异常率与贴边率大降）又可**校正偏差**。
12. **最优 δ 存在但不唯一**，由 β （主导）、 n （次要）决定，**与 η 无关**。
13. 最优 δ 随 β 从 ~ 1.0 ($\beta=0.8$) 单调降到 ~ 0.05 ($\beta=5$)；默认 0.1 只在 $\beta\approx 3$ 附近接近最优。
14. 分层/自适应带来稳定收益：按 β 分层 $\approx +12\%$ 、自适应 $\approx +2\%$ 、逐样本上界 $\approx +31\%$ 。

11.2 最终建议

推荐方案（按使用者掌握的信息分档）

- A. 有形状先验（推荐）：**按 β 分层选 δ （表 7 / 经验式）。性价比最高，捕获约 12% 收益。
 - B. 无先验、数据驱动：**用自适应 $\hat{\delta}(n, \hat{\beta})$ ——先以 0.1 估 $\hat{\beta}$ 再定 δ 重跑。完全可落地，约 +2%。
 - C. 省事且 $\beta\approx 3$ ：**直接用 $\delta=0.1$ ，可接受。
- 不推荐：** $\delta=0$ （经典 $\nabla=0$ ），稳健性与精度均最差。

一句话：把 δ 当成由“形状 β 驱动的可调旋钮”—— β 小则 δ 大、 β 大则 δ 小——并用上面的三步法落地，即可在不改动 MDM 框架的前提下，**稳定且可观地提升三参数威布尔估计的精度**。

11.3 适用范围与局限

- 本研究网格规模适中（150 组场景、每组 300 次重复），结论在所覆盖范围内稳健；极端小样本 ($n<5$) 或极端形状 ($\beta>5$ 、 $\beta<0.8$) 外推需谨慎。
- 最优 δ 的绝对数值依赖于 MDM 的具体实现细节（如分位定义、 β 搜索范围、平滑参数）；迁移到不同实现时建议用本文方法做一次小规模标定。
- 自适应规则的收益受 $\hat{\beta}$ 估计质量限制； $\hat{\beta}$ 越准、收益越接近按真 β 分层。

附录 复现说明

本报告的全部数据与图表均由实际仿真生成，可完全复现。交付目录结构如下：

路径	内容
code/mdm_core.py	MDM 估计核心（采样、 $\sigma_{\min}$ 曲线、偏移量求根）
code/run_mc.py	蒙特卡罗实验驱动，输出 data/ 下原始与聚合结果
code/analyze.py	汇总分析：各层次最优 δ 、策略对比、自适应规则
code/make_figures.py	由实验结果生成全部图 1-10
code/build_report.js + report_content.js	生成本 Word 报告
data/*.npz, *.csv, *.json	逐重复原始结果与聚合指标
figures/*.png	全部图表
README	复现步骤（中文）

复现步骤：①安装依赖 numpy/scipy/matplotlib/pandas 与 Node 包 docx；②运行 *python code/run_mc.py* 生成数据；③运行 *python code/analyze.py* 与 *python code/make_figures.py* 生成指标与图；④运行 *node code/build_report.js* 生成报告。随机种子已固定，结果可重现（数值因 BLAS 实现可能有极小差异）。

— 报告结束 —